

정규표현식(Regular Expression) 상세 분석 리포트 V2

데이터 전처리 및 텍스트 마이닝의 필수 도구

1. 정의 및 개념 설명

정규표현식(Regex)은 특정한 규칙을 가진 문자열의 집합을 표현하는 데 사용하는 형식 언어입니다. 데이터 전처리 단계에서 불필요한 특수문자 제거, 데이터 정제, 패턴 기반 치환 등에 필수적으로 활용됩니다.

2. 정규표현식 핵심 문법 및 중요도

기호	의미	예시	중요도
.	임의의 한 문자	a.b (acb, a1b 등)	★★★★☆☆
* / +	0회 / 1회 이상 반복	ab*, ab+	★★★★★★
?	0회 또는 1회 존재	ab?	★★★★★☆☆
^ / \$	시작 / 끝 표시	^abc, abc\$	★★★★★☆☆
[]	문자 집합 (범위)	[a-z], [0-9]	★★★★★★
\d / \s	숫자 / 공백	\d+	★★★★★★
	OR (선택)	apple orange	★★★★★☆☆

3. Python 실전 활용: 데이터 치환 및 정제 (re.sub)

re.sub(pattern, repl, string) (중요도: ★★★★★)

설명: 문자열 내에서 정규표현식 패턴과 일치하는 부분을 다른 문자열(repl)로 치환합니다. 데이터 전처리에서 가장 많이 활용되는 함수입니다.

주요 활용 사례:

- **특수문자 제거:** 한글, 영문, 숫자만 남기고 나머지(기호 등) 삭제
- **데이터 정규화:** 날짜 형식을 변경하거나 전화번호 대시(-) 제거
- **불용어 제거:** 텍스트 마이닝 시 분석에 방해되는 단어 일괄 교체

[Python 코드 예시: 한글만 남기기]

```
import re
text = "안녕하세요! Hello World... 1234 #특수문자"
clean_text = re.sub('[^가-힣 ]', '', text)
결과: "안녕하세요 특수문자"
```

4. 기타 주요 함수

- **re.findall():** 패턴과 일치하는 모든 문자열을 리스트로 반환 (중요도: ★★★★★)
- **re.search():** 문자열 전체에서 첫 번째 일치 항목 검색 (중요도: ★★★★★☆)
- **re.split():** 패턴을 기준으로 문자열을 분할하여 리스트화 (중요도: ★★★★★☆)

5. 효율적인 사용 팁

- **Raw String 사용:** 파이썬에서는 백슬래시(\) 처리를 위해 `r'\d'` 와 같이 문자열 앞에 'r'을 붙이는 것을 권장합니다.
- **Compile 활용:** 동일한 패턴을 반복해서 사용할 경우 `p = re.compile(pattern)` 으로 미리 컴파일하면 속도가 빨라집니다.